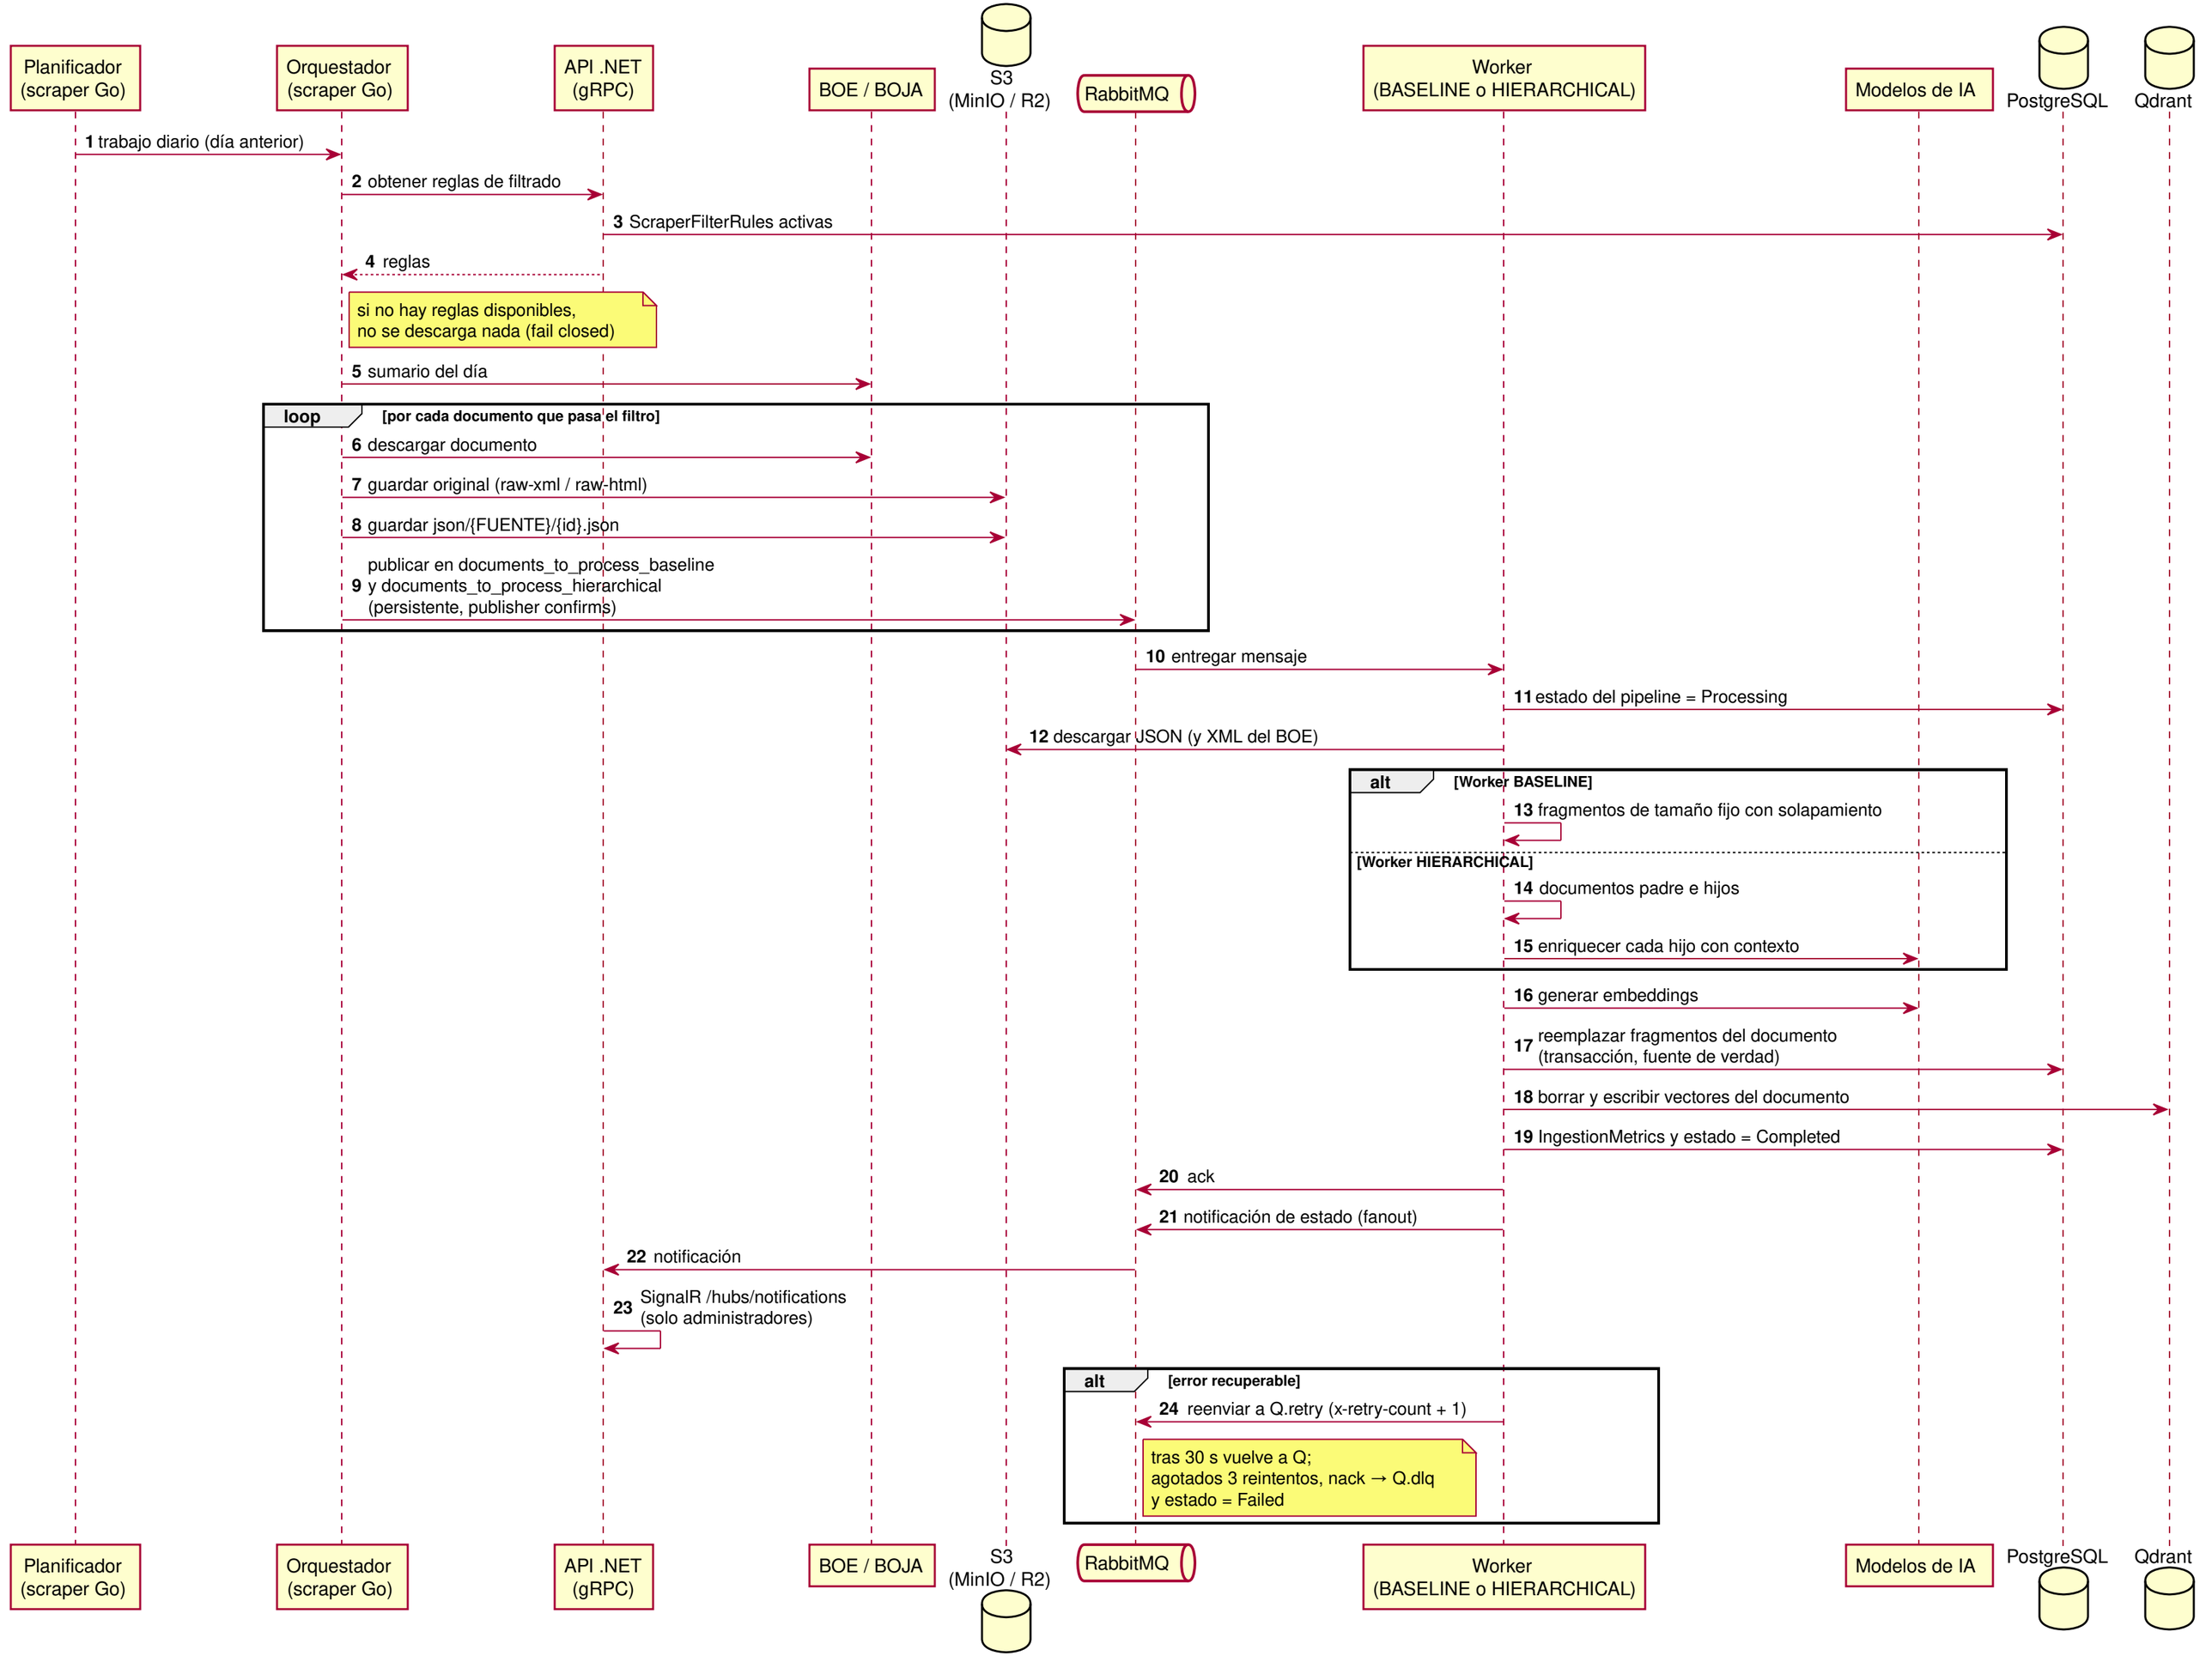
Planificador (scraper Go)
Orquestador (scraper Go)
API .NET (gRPC)
BOE / BOJA
S3 (MinIO / R2)
RabbitMQ
Worker (BASELINE o HIERARCHICAL)
Modelos de IA
PostgreSQL
Qdrant
1 trabajo diario (día anterior)
2 obtener reglas de filtrado
3 ScraperFilterRules activas
4 reglas
si no hay reglas disponibles, no se descarga nada (fail closed)
5 sumario del día
loop
[por cada documento que pasa el filtro]
6 descargar documento
7 guardar original (raw-xml / raw-html)
8 guardar json/{FUENTE}/{id}.json
9 publicar en documents_to_process_baseline y documents_to_process_hierarchical (persistente, publisher confirms)
10 entregar mensaje
11 estado del pipeline = Processing
12 descargar JSON (y XML del BOE)
alt
[Worker BASELINE]
13 fragmentos de tamaño fijo con solapamiento
[Worker HIERARCHICAL]
14 documentos padre e hijos
15 enriquecer cada hijo con contexto
16 generar embeddings
17 reemplazar fragmentos del documento (transacción, fuente de verdad)
18 borrar y escribir vectores del documento
19 IngestionMetrics y estado = Completed
20 ack
21 notificación de estado (fanout)
22 notificación
23 SignalR /hubs/notifications (solo administradores)
alt
[error recuperable]
24 reenviar a Q.retry (x-retry-count + 1)
tras 30 s vuelve a Q; agotados 3 reintentos, nack → Q.dlq y estado = Failed